



Módulo II: Análisis y visualización de Datos

Proyecto I:

Análisis exploratorio de datos (EDA) **Completo**

Contexto / Situación profesional:

Una consultora de Recursos Humanos especializada en perfiles tech — DataTalent Solutions S.L. — necesita entender con precisión qué habilidades técnicas demanda el mercado laboral español en roles de datos. Hasta ahora, sus asesores orientan a los candidatos basándose en intuición y tendencias generales del sector, lo que genera desajustes entre las habilidades de los candidatos y las expectativas reales de las empresas.

El equipo directivo quiere lanzar una nueva línea de reskilling y necesita evidencia empírica antes de diseñar el programa. Os contratan como analistas de datos junior para realizar un análisis exploratorio completo sobre ofertas de empleo reales.

Problema / necesidad:

El proyecto debe responder a las siguientes preguntas de negocio:

- ¿Qué skills técnicas se piden con más frecuencia en roles de datos en España?
- ¿Existen sesgos en la distribución salarial según género, ciudad o tipo de contrato?
- ¿Qué sectores industriales concentran más ofertas y mejoras salariales?
- ¿Qué correlaciones existen entre años de experiencia, skills y salario ofertado?
- ¿Qué decisiones se toman con datos incompletos o sesgados, y cuál es su impacto potencial?

💡 Clave del proyecto: no basta con calcular estadísticos. El equipo debe interpretar cada hallazgo en clave de negocio y reflexionar sobre qué decisiones podrían tomarse erróneamente si los datos tienen sesgos.



Producto final esperado:

- **Notebook en Colab o Jupyter** limpio y documentado con el EDA completo (celdas Markdown entre cada bloque de código)
- **Repositorio GitHub** con README estructurado, dataset, notebook y capturas de las visualizaciones principales
- **Presentación ejecutiva** (slides, 10 min) con hallazgos clave y recomendaciones para la consultora, orientada a audiencia no técnica
- **Informe de sesgos** (sección dentro del notebook): qué sesgos encontraron, cómo los detectaron y qué impacto tendrían en un modelo predictivo.

Dataset recomendado:

- **Data Science Job Salaries** (Kaggle) — salarios globales 2020–2024 en roles de datos, con país, nivel, modalidad y herramientas
- **Stack Overflow Developer Survey** — encuesta anual con sesgos demográficos documentados, ideal para la sección de sesgos
- **LinkedIn Job Postings (Kaggle)** — +30 k ofertas con skills, salario y sector

Conocimientos técnicos:

Fase 1 — Exploración inicial

- Cargar datasets con **pandas.read_csv()**, inspeccionar **.shape**, **.dtypes**, **.info()**, **.describe()**
- Identificar variables numéricas vs. categóricas
- Detectar y cuantificar valores nulos: **.isnull().sum()**

Fase 2 — Limpieza y preparación

- Tratamiento de nulos: imputación con mediana/moda o eliminación justificada
- Detección de outliers: rango intercuartílico (IQR), z-score con NumPy
- Normalización de textos: **.str.lower()**, **.str.strip()**, **.str.replace()**
- Documentar cada decisión de limpieza con justificación en Markdown

Fase 3 — Análisis estadístico y sesgos

- Estadística descriptiva: media, mediana, desviación estándar, percentiles
- Correlaciones: **.corr()** de Pandas, heatmap con Seaborn
- Análisis de grupos: **.groupby()** y **pivot_table()**



- Identificación de sesgos en datasets: subrepresentación, datos faltantes no aleatorios (MNAR)
- Probabilidad condicional básica: $P(A|B)$ interpretada en contexto real

Fase 4 — Visualización

- Mínimo 6 gráficos: histogramas, boxplots, barras, dispersión, heatmap de correlaciones
- Al menos 1 visualización que muestre una distribución (Normal o similar) sobre datos reales
- Cada gráfico con: título, etiquetas de ejes, leyenda cuando aplique, e interpretación escrita en Markdown

Competencias:

- **C3 – Preparar datos para el entrenamiento de modelos de inteligencia artificial**
 - **Nivel 2 (Adaptar):** Preparar datos ajustando el proceso a un contexto conocido y a un objetivo concreto.
- **C5 – Programar aplicaciones y lógica de negocio mediante lenguajes de programación**
 - **Nivel 2 (Adaptar):** Desarrollar funciones y módulos organizados para una aplicación específica, ajustando la lógica a un objetivo concreto.
- **C7. Gestionar el aprendizaje de forma autónoma en entornos de aprendizaje activo**
 - **Nivel 2 (Adaptar):** Organizar su aprendizaje en función de objetivos conocidos, utilizando recursos de forma autónoma y ajustando su ritmo.
- **C8 – Desarrollar un proyecto aplicado en equipo y comunicar resultados técnicos**
 - **Nivel 2 (Adaptar):** Contribuir activamente al proyecto y comunicar resultados ajustando el mensaje al contexto profesional.
- **C10 – Aplicar criterios éticos, sociales y de gobernanza en el desarrollo y uso de la inteligencia artificial**
 - **Nivel 1 (Imitar):** Reconocer riesgos éticos y principios básicos de gobernanza (privacidad y calidad) asociados al uso de la inteligencia artificial a partir de ejemplos claros y explicaciones proporcionadas.
 - **Nivel 2 (Adaptar):** Analizar un caso concreto de uso de inteligencia artificial e identificar sus posibles impactos sociales, proponiendo medidas básicas de mitigación.



Criterios de rendimiento:

- **Exploración y limpieza:** Rigor en cisión, justificación documentada de cada tratamiento de nulos y outliers
- **Análisis estadístico:** Uso correcto de descriptivos, correlacionaes e interpretación en clave de negocio.
- **Detección de sesgos:** Identificación crítica de sesgos y reflexión sobre su impacto en decisiones.
- **Visualizaciones:** Claridad, variedad, interpretación escrita de cada visual

Checklist de evaluación:

I. Exploración y limpieza

- ☐ Se carga el dataset y se inspecciona con `.shape()` `.dtypes()` `.describe()`
- ☐ Se identifican y cuantifican valores nulos
- ☐ Se detectan outliers y se documenta la decisión tomada
- ☐ Se normalizan textos

II. Análisis estadístico

- ☐ Se calculan media, mediana y desviación estándar de al menos 3 variables clave
- ☐ Se calcula una matriz de correlaciones y se interpreta
- ☐ Se usa `groupby()` para comparar grupos (por ciudad, nivel, sector...)
- ☐ Cada resultado estadístico tiene una interpretación en lenguaje natural (celda Markdown)

III. Sesgos

- ☐ Se identifican al menos 2 sesgos presentes en el dataset
- ☐ Se explica el origen del sesgo (recolección, etiquetado, subrepresentación...)
- ☐ Se reflexiona sobre el impacto que tendría ese sesgo en un modelo predictivo

IV. Visualizaciones

- ☐ Mínimo 6 gráficos distintos (tipologías variadas)
- ☐ Al menos 1 gráfico de distribución (histograma con curva normal o KDE)
- ☐ Todos los gráficos tienen título, etiquetas de ejes y una interpretación escrita

V. Funcionalidades opcionales

- ☐

VI. Presentación Oral

- ☐ Contexto y datos: ¿Qué dataset usaron, por qué y qué preguntas querían responder?



- ☐ Hallazgos clave: 3-4 Insights concretos con visualizaciones
- ☐ Sesgos encontrados: ¿Qué se detectó y qué implicaciones tiene para la consultora?
- ☐ Recomendaciones: ¿Qué acciones concretas se le puede proponer al cliente?

Modalidades pedagógicas:

- **Módulo II:** Análisis y Visualización de Datos
- **Aprendizaje colaborativo:** Trabajo en pair programming (alternado)
- **Plazos:** Duración estimada 2 semanas
- **Metodología:** Tipo Agile adaptadas a nivel principiante - Intermedio
- **Herramientas de colaboración:** Git, GitHub, Google Colab, VSCode, Trello, Kanban
- **Acompañamiento y evaluación formativa:** Check points guiados y mini retos de depuración (inputs inválidos).

Recursos y Apoyos:

Datasets

- [Data Science Job Salaries:](#)
- [Stack Overflow Developer Survey:](#)
- [LinkedIn Job Postings:](#)

Documentación técnica

- [¿Qué es el análisis exploratorio de datos \(EDA\)? IBM](#)
- [Pandas User Guide:](#)
- [Seaborn Gallery:](#)
- [NumPy Quickstart:](#)

Glosario de términos:

Término	Definición
EDA (Exploratory Data Analysis)	Análisis exploratorio de datos: proceso de examinar un dataset para resumir sus características principales usando estadística y visualización, antes de aplicar modelos.



Valor nulo (NaN)	Entrada de dato que no contiene ningún valor. Puede deberse a errores de recolección, campos opcionales no completados o pérdida de información.
Outlier	Valor atípico que se aleja significativamente del resto de observaciones. Puede ser un error o un caso genuino que merece atención.
Desviación estándar	Medida de dispersión que indica cuánto se alejan, en promedio, los valores de la media. Cuanto mayor, más dispersión.
Correlación	Medida estadística que expresa en qué grado dos variables cambian juntas. Va de -1 (inversa perfecta) a +1 (directa perfecta). 0 indica sin relación lineal.
Sesgo (Bias)	Tendencia sistemática en los datos que hace que ciertos grupos estén sobre o subrepresentados, distorsionando los análisis y las conclusiones.
MNAR (Missing Not At Random)	Patrón de valores faltantes donde la ausencia del dato está relacionada con el propio valor no observado (ej: personas con salarios muy altos no los reportan).
Probabilidad condicional	Probabilidad de que ocurra un evento A sabiendo que ya ocurrió B. Notación: $P(A B)$. Útil para analizar relaciones entre variables categóricas.
Heatmap de correlaciones	Visualización matricial donde cada celda muestra la correlación entre dos variables, codificada en color (rojo = positiva, azul = negativa).
Pair programming	Técnica de desarrollo en la que dos personas trabajan juntas en un mismo código: una escribe (Driver) y la otra revisa y orienta (Navigator).
Reskilling	Proceso de capacitar a una persona en nuevas habilidades para adaptarse a un cambio de rol o sector profesional.
IQR (Rango Intercuartílico)	Diferencia entre el percentil 75 y el percentil 25. Se usa para detectar outliers: valores fuera de $[Q1 - 1.5 \cdot IQR, Q3 + 1.5 \cdot IQR]$ se consideran atípicos.